MÓDULO 1

Fundamentos de la Calidad de Datos

Dra. Ing. Roxana Martínez

1.1 Concepto y dimensiones de calidad de datos

Calidad de Software

La calidad de software se puede definir como "***el grado en que un sistema, componente o proceso de software cumple con los requisitos especificados, necesidades o expectativas del usuario y/o del cliente***" (ISO/IEC 25010:2011).

Norma ISO/IEC 25010, que se centra en la evaluación de la calidad del producto de software.

Calidad de Software

IEEE define la calidad de software como "***la concordancia con los requisitos funcionales y de rendimiento explícitamente establecidos, con los estándares de desarrollo explícitamente documentados y con las características implícitas que se espera de todo software profesionalmente desarrollado***" (IEEE Std 610.12-1990).

"***la satisfacción del usuario con respecto a cómo el software cumple sus necesidades, incluidas sus expectativas de funcionalidad, rendimiento, fiabilidad, facilidad de uso, facilidad de aprendizaje, seguridad y capacidad de modificación***" (Boehm, 1981).

CALIDAD

Análisis
Código Limpio
Aprendizaje Continuo
La Calidad del Software
Refactorizac
Desarrollo Ágil
Pruebas

Algunos aspectos clave que influyen en la calidad del software:

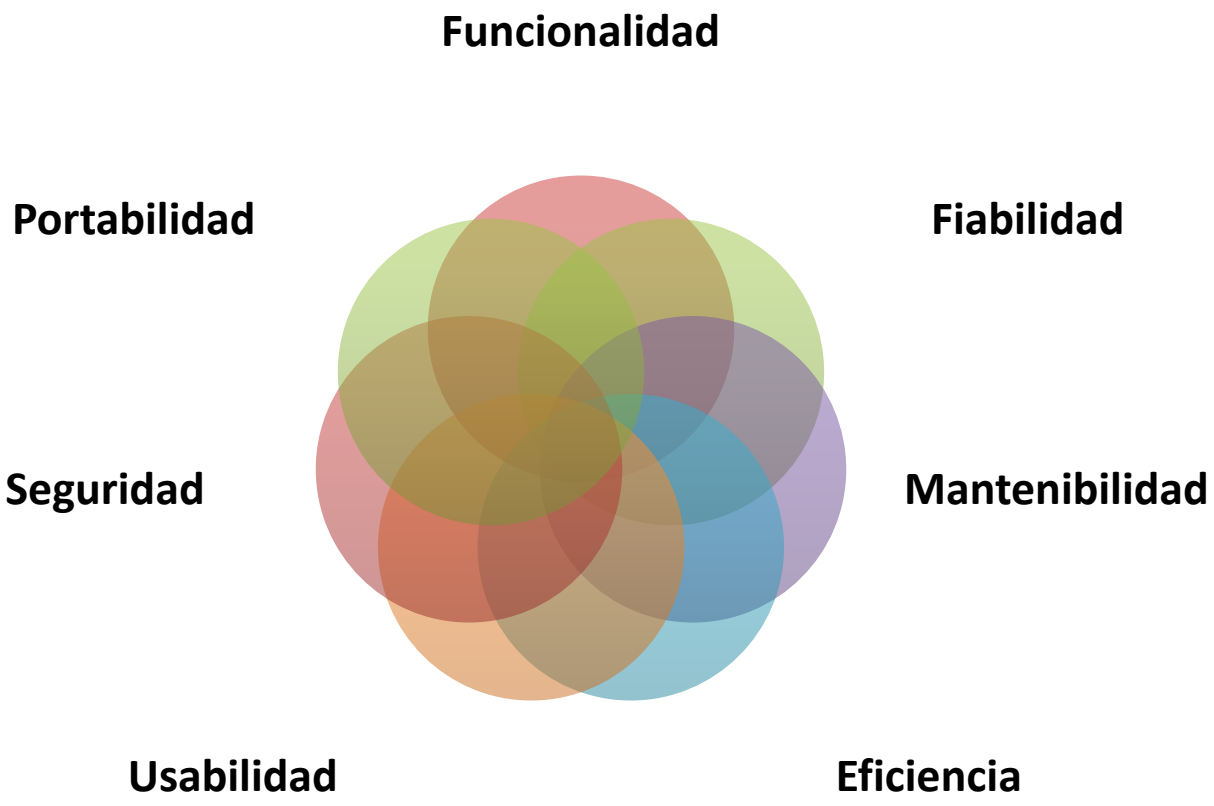

Problemática

DEBATE:

¿Por qué es fundamental mantener la calidad de software?

DEBATE: RESPUESTA

La calidad del software es fundamental, ya que un **software de baja calidad puede llevar a errores costosos**, **problemas de seguridad** y **descontento de los usuarios**.

Por otro lado, un software de alta calidad puede generar una mayor satisfacción del cliente, reducir costos operativos y mejorar la productividad general.

Para garantizar y mejorar la calidad del software, se aplican diversas prácticas y metodologías de desarrollo, como pruebas exhaustivas, revisión de código, automatización de pruebas, seguimiento de métricas de calidad y uso de estándares de desarrollo reconocidos.

Calidad de Datos

DATOS

Pueden ser de diferentes tipos y formatos, como números, texto, imágenes, archivos, registros de bases de datos, entre otros.

DATOS

Los datos son fundamentales en el desarrollo y funcionamiento de cualquier software, ya que permiten que el programa realice cálculos, tome decisiones, almacene información, interactúe con los usuarios y genere resultados.

CALIDAD DE DATOS

La calidad de datos se da cuando los datos se ajustan al propósito para el que fueron destinados. Los datos también se consideran de alta calidad cuando representan con precisión los conceptos del mundo real.

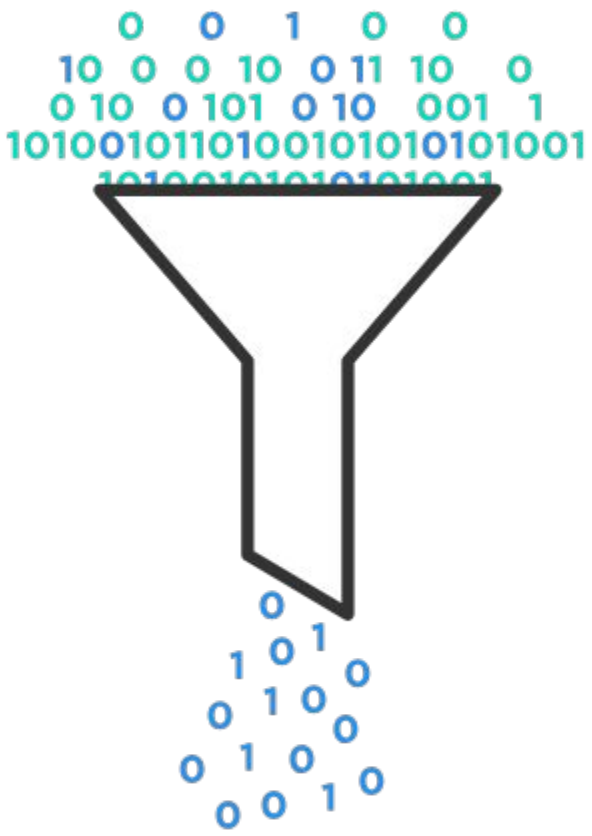

CALIDAD DE DATOS

"los datos son la piedra angular de una jerarquía que se construye sobre ellos. Sobre la base de los datos, viene la información, que son datos colocados en contexto.

*De la **información** procesable surge el **conocimiento**, que se convierte en sabiduría cuando se aplica.*

PROBLEMAS CON CALIDAD DE DATOS

Los datos de mala calidad darán como resultado una mala calidad de la información, y esto sube en la jerarquía, lo que da como resultado malas decisiones comerciales”.

1.2 Ciclo de vida de los datos: Desde la generación hasta la eliminación

Ciclo de vida del dato

El ciclo de vida del dato es un concepto que describe las diferentes etapas por las que atraviesa un dato desde su creación o captura hasta su eventual eliminación o archivo.

Estas etapas típicamente incluyen la creación, almacenamiento, uso, mantenimiento y, finalmente, la eliminación o archivo del dato.

Ciclo de vida del dato

Es importante destacar que el ciclo de vida del dato no es una secuencia lineal estricta; las etapas pueden variar según el tipo de dato y el contexto en el que se encuentre.

Además, con la creciente conciencia sobre la privacidad y seguridad de los datos, es fundamental que las organizaciones sigan prácticas y políticas adecuadas para el manejo responsable de los datos a lo largo de su ciclo de vida.

Ciclo de vida del dato

¿Qué es la gestión del ciclo de vida de los datos?

La gestión del ciclo de vida de los datos (DLM) es un enfoque para gestionar los datos en su ciclo de vida, desde la entrada hasta la destrucción de los datos. Los datos se separan en fases en función de diferentes criterios y se mueven a través de estas etapas a medida que completan diferentes tareas o cumplen ciertos requisitos. ***Un buen proceso de DLM proporciona estructura y organización a los datos de una empresa, lo que a su vez permite objetivos principales dentro del proceso, como la seguridad y la disponibilidad de los datos.***

Ciclo de vida del dato

1. **Creación y Captura**: En esta etapa, los datos se generan o capturan desde diversas fuentes, como sensores, sistemas de registro, formularios en línea o interacciones de usuarios.

1. **Almacenamiento y Respaldo**: Los datos se almacenan en bases de datos, sistemas de archivos o almacenamiento en la nube para su posterior acceso y uso.

1. **Procesamiento y Uso**: Los datos se procesan para extraer información significativa, realizar análisis, generar informes y apoyar la toma de decisiones.

1. **Integración y Calidad de Datos**: Los datos pueden provenir de diversas fuentes y es necesario integrarlos para garantizar la consistencia y calidad de los mismos.

Ciclo de vida del dato

5. Compartir y Distribuir: En algunos casos, los datos se comparten con otras partes interesadas, equipos o sistemas para su utilización en diferentes contextos.

6. Mantenimiento y Actualización: Se llevan a cabo acciones para mantener los datos actualizados y precisos a lo largo del tiempo.

7. Privacidad y Seguridad: La protección de los datos y la garantía de su privacidad son factores críticos en todas las etapas del ciclo de vida.

8. Archivo y Eliminación: Los datos que ya no son necesarios pueden archivarse para referencia futura o eliminarse de manera segura según las políticas de retención de datos.

Beneficios: Ciclo de vida del dato

- Mejora de procesos
- Control de costos
- Usabilidad de los datos
- Usabilidad de los datos

Fuente: https://www.ibm.com/mx-es/topics/data-lifecycle-management

1.3.1 Gestión de datos: Conceptos básicos y buenas prácticas

CALIDAD DE DATOS: CARACTERÍSTICAS

Los datos poseen diversas características que describen sus atributos y cualidades. Algunas de las características más importantes de los datos son las siguientes:

Precisión: La precisión se refiere a la exactitud y fiabilidad de los datos, es decir, qué tan cercanos están los valores a la realidad o al valor verdadero.

Datos precisos son fundamentales para obtener resultados confiables y tomar decisiones informadas.

CALIDAD DE DATOS: CARACTERÍSTICAS

Complejidad: Los datos pueden variar en su complejidad, desde valores simples como números enteros o caracteres hasta estructuras más complicadas como bases de datos con múltiples tablas y relaciones.

Tipo: Los datos pueden clasificarse en diferentes tipos, como datos numéricos (enteros, decimales), datos alfanuméricos (texto), datos binarios (0 y 1) o datos multimedia (imágenes, audio, video).

CALIDAD DE DATOS: CARACTERÍSTICAS

Volumen: El volumen de datos hace referencia a la cantidad de información que se encuentra disponible.

Velocidad: La velocidad se refiere a la rapidez con la que los datos son generados, procesados y transmitidos.

Veracidad: referencia a la confiabilidad y autenticidad de los datos. Es importante que los datos sean veraces y provengan de fuentes confiables para evitar la propagación de información incorrecta o falsa.

CALIDAD DE DATOS: CARACTERÍSTICAS

Consistencia: La consistencia se refiere a que los datos deben mantener un formato uniforme y coherente en toda su estructura para asegurar su correcta interpretación y uso.

Actualidad: indica qué tan recientes son y si siguen siendo válidos para el propósito actual. En ciertas situaciones, los datos más antiguos pueden haber perdido relevancia o ser menos útiles.

Accesibilidad: facilidad con la que se puede acceder a los datos. La disponibilidad de datos juega un papel crucial en la toma de decisiones informadas.

INTEGRIDAD DE DATOS

Figura 1. DAMA-DMBOK Data Management Framework

1.3.2 Gestión de calidad de datos y DAMA DMBOK

Figura 1. DAMA-DMBOK Data Management Framework

MDM (Master Data Management)

La gestión de datos maestros (MDM) surgió de la necesidad de las empresas de mejorar la coherencia y la calidad de sus activos de datos clave, como datos de productos, datos de activos, datos de clientes, datos de ubicación, etc.

MDM (Master Data Management)

La gestión de datos maestros, también conocida como ***MDM*** (Master Data Management), es un conjunto de procesos y tecnologías utilizadas para garantizar la calidad, coherencia, integridad y disponibilidad de los datos maestros en una organización.

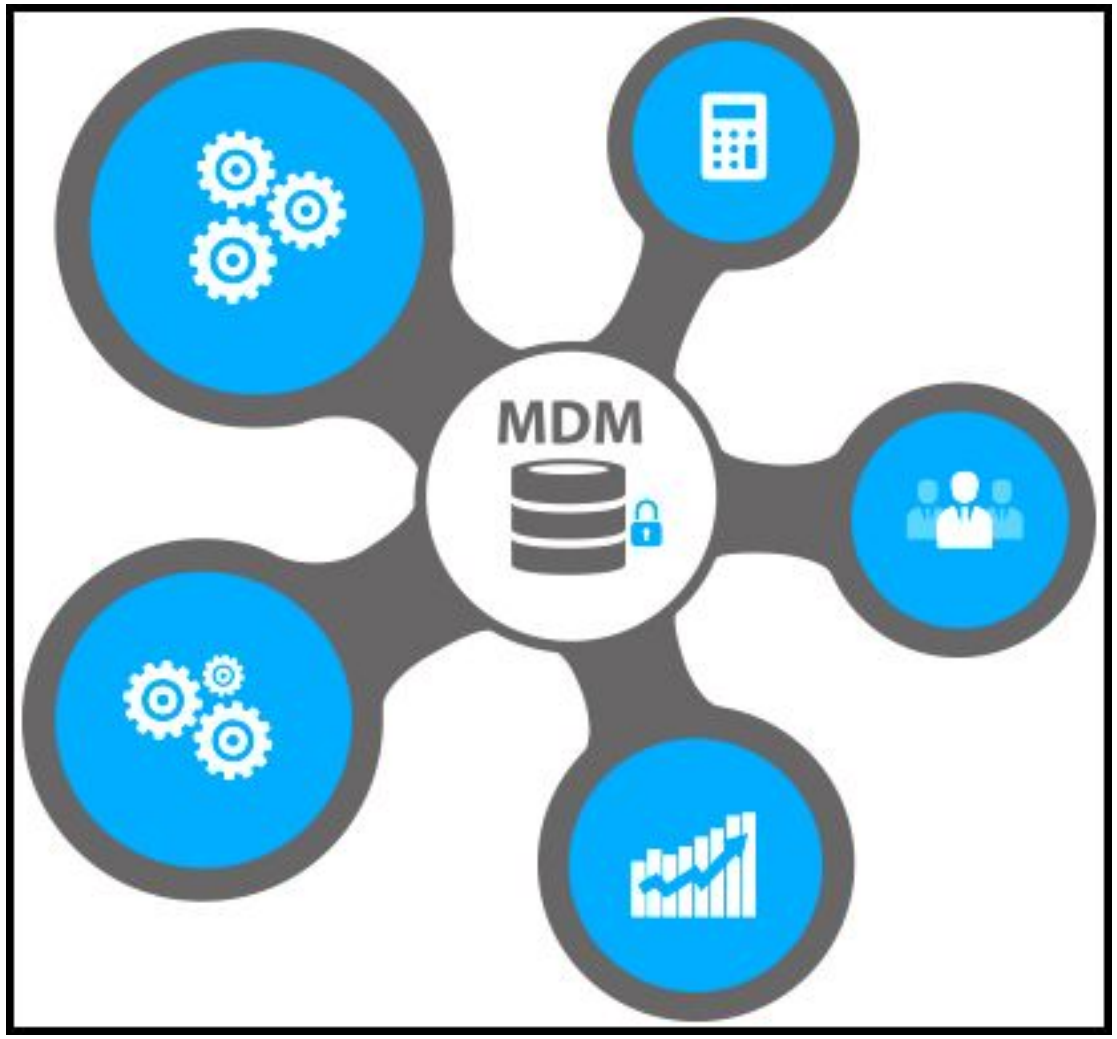

MDM (Master Data Management)

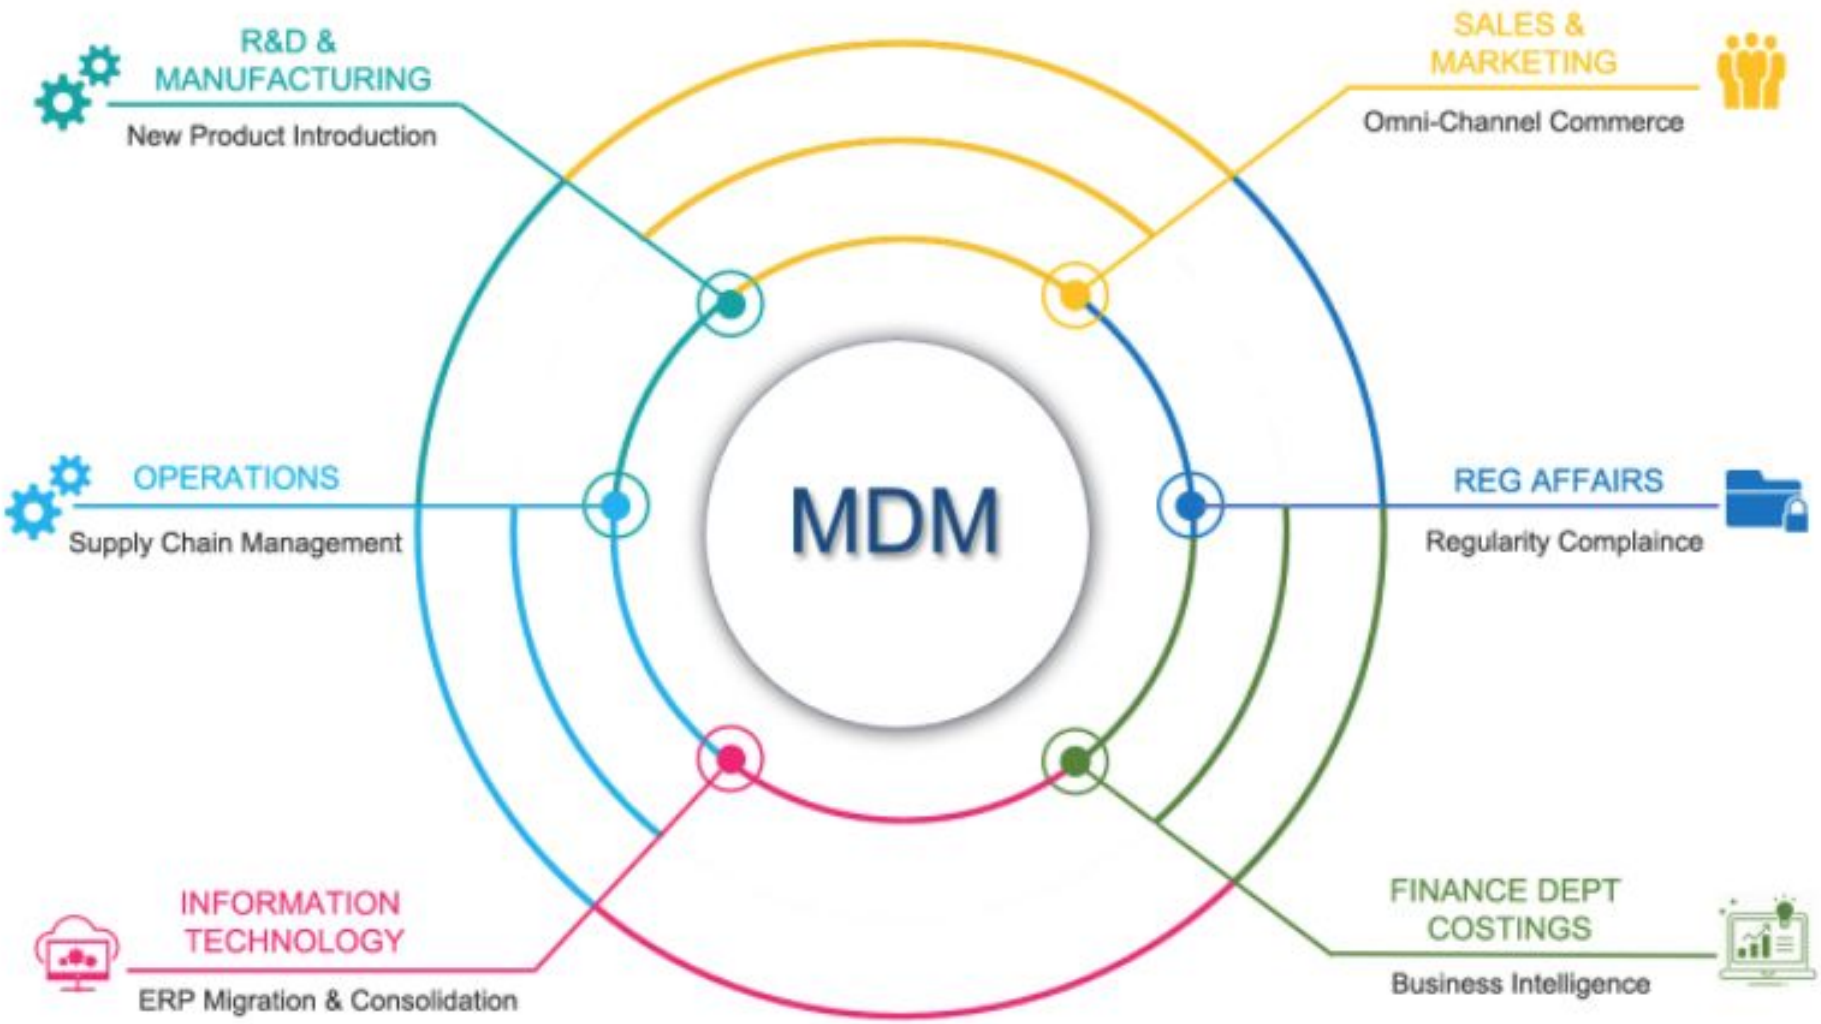

MDM (Master Data Management)

*Los **datos maestros** son aquellos datos fundamentales y comunes que describen las entidades principales con las que una empresa opera, como clientes, proveedores, productos, empleados, etc.*

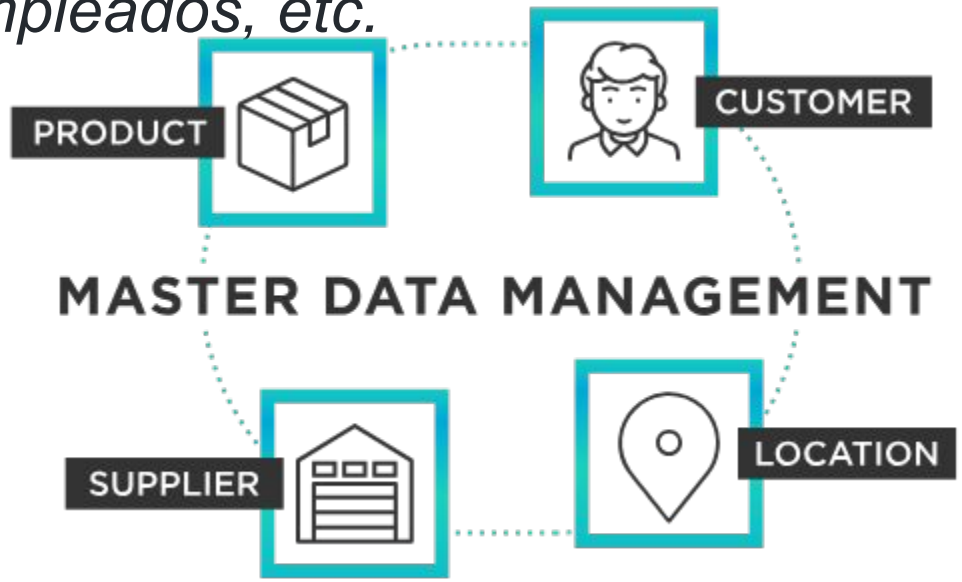

Estos datos son utilizados por diversas aplicaciones y sistemas dentro de la organización y deben estar bien gestionados para evitar problemas de calidad de datos y garantizar la toma de decisiones correctas.

5 tipos de datos

No estructurados: Son datos que se encuentran en correos electrónicos, documentos en PDF, white papers, artículos de revistas, portales de una intranet corporativa, especificaciones de productos, información de marketing, etc.

Transaccionales: Se trata de datos relacionados con ventas, entregas, facturas, tickets de asistencia, reclamaciones y otras interacciones monetarias y no monetarias. diferencia de los datos maestros, las transacciones son inherentemente temporales e instantáneas por naturaleza.

5 tipos de datos

Metadatos: Son datos sobre otros datos y pueden residir en un repositorio formal o en otras diferentes formas como documentos XML, definiciones de informes, descripciones de columnas en una base de datos, ficheros log, conexiones y ficheros de configuración.

5 tipos de datos

Datos jerárquicos: Almacenan las relaciones entre otros datos.
Pueden ser almacenados como parte de un sistema contable o por separado como descripciones de las relaciones del mundo real, como estructuras organizativas de la empresa o líneas de productos.

Los datos jerárquicos a veces se consideran un súper dominio del MDM, porque es crítico de entender y a veces descubrir las relaciones entre los datos maestros.

5 tipos de datos

Maestros:

Son los datos críticos de un negocio y caen generalmente dentro de 4 grupos: ***personas, cosas, lugares y conceptos***. Otras categorizaciones dentro de esas agrupaciones se denominan áreas temáticas, áreas de dominio o tipos de entidad. Por ejemplo, dentro del grupo de personas hay clientes, empleados y vendedores

Herramientas de Software de MDM

Elige el software MDM más indicado:

- Modelo de creación de datos y relaciones automatizadas
- Administración de metadatos
- Herramientas de análisis.
- Administración de servicios. Tu herramienta debe trabajar con tus datos maestros para así extraer información y agrupar elementos.

Herramientas de Software de MDM

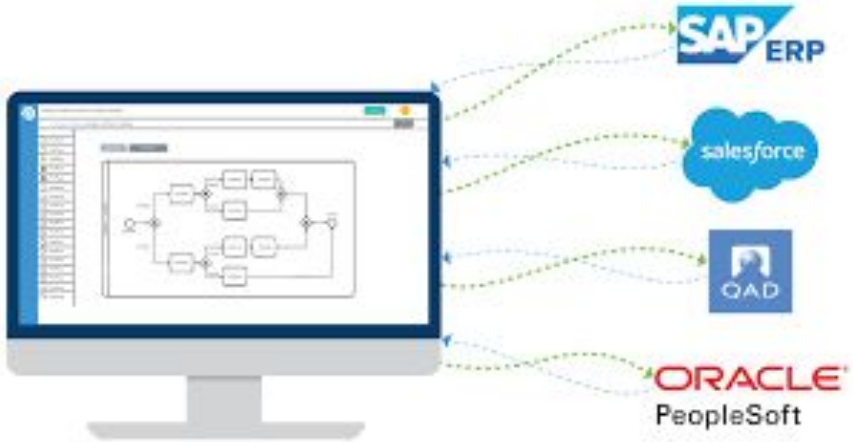

- Informatica MDM
- IBM InfoSphere MDM
- SAP Master Data Governance (MDG)
- Talend MDM
- Reltio
- Stibo Systems STEP
- Semarchy xDM
- Profisee

Herramientas de Software de MDM - Gratuitas

Talend MDM Community Edition: Talend ofrece una versión de código abierto de su solución MDM llamada "Talend MDM Community Edition". Esta versión gratuita permite la gestión de datos maestros básicos y es adecuada para proyectos más pequeños o con requisitos menos complejos.

Profisee MDM Community Edition: Profisee ofrece una edición gratuita de su plataforma de gestión de datos maestros llamada "Profisee MDM Community Edition". Esta versión es ideal para proyectos más pequeños y permite la gestión de datos de clientes y otros datos maestros clave.

Semarchy xDM Community Edition: Semarchy ofrece una edición gratuita de su plataforma de gestión de datos maestros llamada "Semarchy xDM Community Edition". Esta versión proporciona capacidades de gestión de datos maestros y es adecuada para proyectos con requisitos más sencillos.

1.4 Impacto organizacional de los datos deficientes

Categorías de Datos

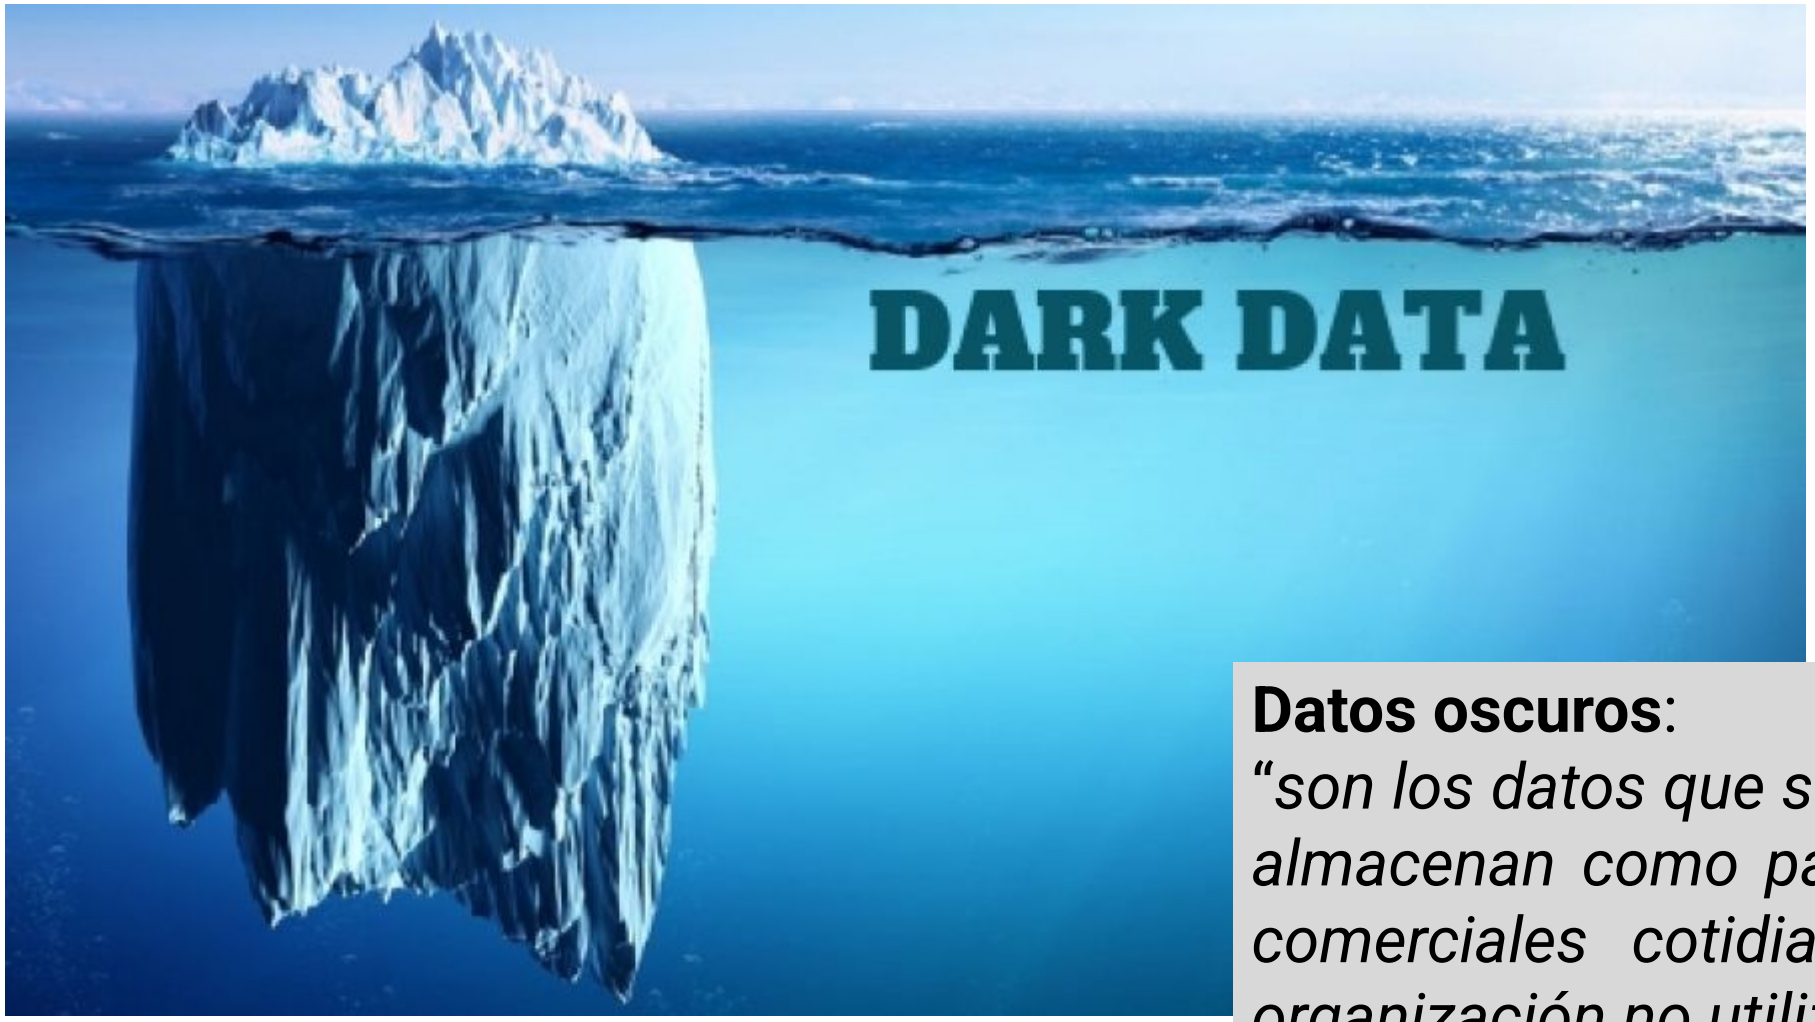

Datos oscuros:
"son los datos que se recopilan, procesan y almacenan como parte de las actividades comerciales cotidianas, pero que no la organización no utiliza con ningún otro fin".

Categorías de Datos

Datos sucios:
En el ámbito de sistemas automatizados, los datos sucios pueden causar a la organización un daño real, al obligarla a incurrir en un costo económico real causado por las acciones automáticas que dan inicio con datos que no son válidos.

1.7 Herramientas básicas: Tableau, Power BI, Python para análisis de datos

Función	Tableau	Power BI	Python
Visualización	Alta calidad visual y numerosas opciones de gráficos. Ofrece mapas, gráficos avanzados y visualizaciones personalizables.	Gráficos dinámicos, opciones de personalización y facilidad para crear dashboards interactivos.	Personalizable con bibliotecas como Matplotlib, Seaborn y Plotly, pero requiere programación.
Interactividad	Excelente para explorar visualmente y construir historias con datos. Las hojas de trabajo pueden enlazarse para crear narrativas.	Alta interactividad en los dashboards; permite filtrar, resaltar y navegar entre diferentes gráficos.	Necesita programación avanzada para interactividad, pero bibliotecas como Plotly ofrecen herramientas interactivas.

Función	Tableau	Power BI	Python
Conectores de datos	Gran cantidad de conectores, incluyendo bases de datos, archivos locales y servicios en la nube.	Amplia variedad de conectores y excelente integración con otros servicios de Microsoft.	Importación de datos usando bibliotecas como Pandas y SQLAlchemy; integración con APIs y archivos locales.
Preparación de datos	Herramientas integradas para la limpieza y transformación de datos, aunque limitadas para procesos complejos.	Funciones de Power Query para transformación y limpieza, intuitivas y potentes.	Amplias capacidades de transformación con Pandas y NumPy; ideal para tareas complejas de procesamiento.
Análisis avanzado	Tiene opciones estadísticas básicas; análisis avanzado posible a través de extensiones.	Análisis estadístico y modelos predictivos básicos, más limitados que Tableau o Python.	Muy potente en análisis avanzado; permite modelos estadísticos, machine learning, y más, usando Scikit-learn, TensorFlow, etc.

Tableau y Power BI son ideales para tareas de **visualización y creación de dashboards** rápidos y visualmente atractivos, con un enfoque en la **interactividad**.

Python es la opción más versátil para **análisis avanzado** y **transformación de datos** compleja, pero requiere conocimientos de programación.

EJERCICIO [CASO PRÁCTICO]

Power BI

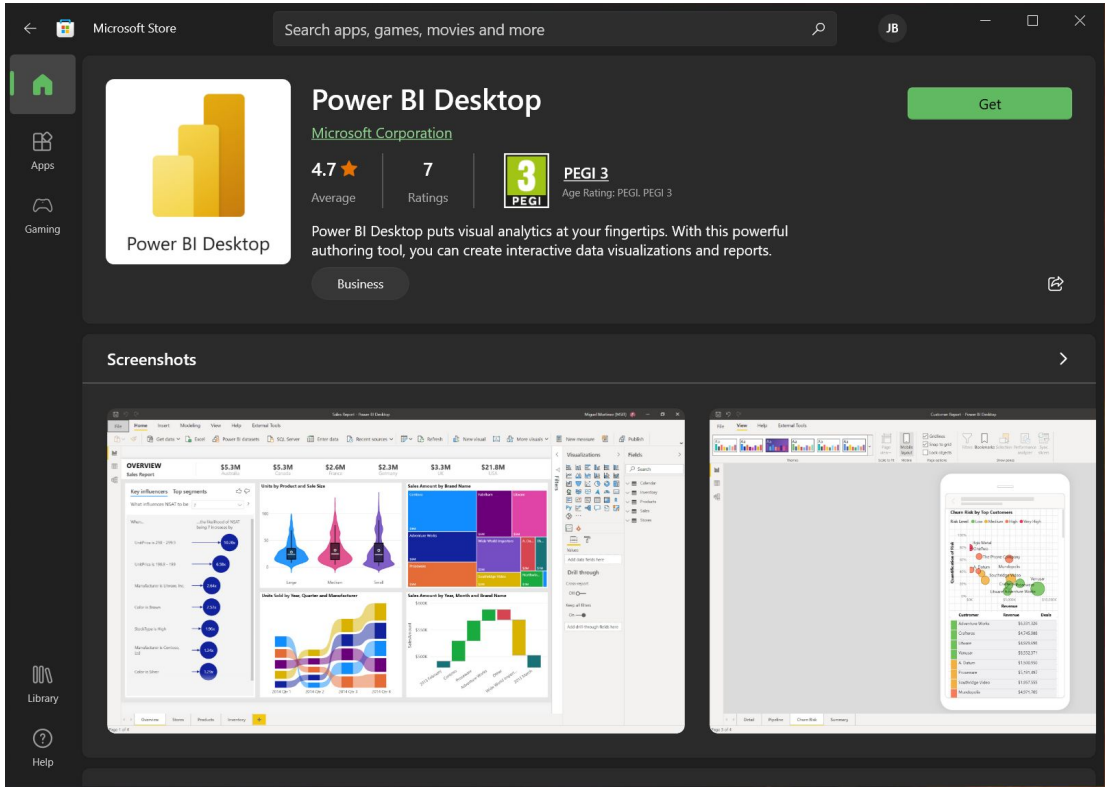

Dra. Ing. Roxana Martínez