MÓDULO 1

Fundamentos de la Calidad de Datos

PARTE II

Dra. Ing. Roxana Martínez

Dra. Ing. Roxana Martínez

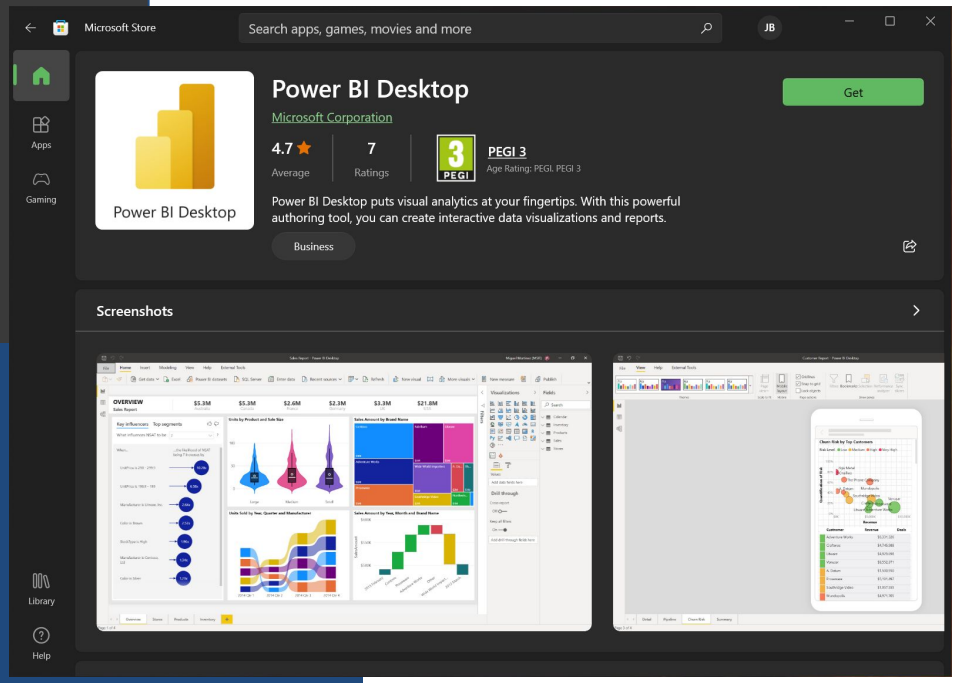

Revisión de los ejercicios [Power BI]

MÓDULO 2

Profilado, limpieza y transformación

PARTE I

Dra. Ing. Roxana Martínez

Temario

MÓDULO 2: PROFILADO, LIMPIEZA Y TRANSFORMACIÓN

2.1 Identificación y corrección de errores: Valores faltantes, duplicados, inconsistencias.
2.2.Transformación de datos: estandarización.
2.3 Profilado de datos y análisis exploratorio

Ejercicio Actividad Asincrónica

2.1 Identificación y corrección de errores: Valores faltantes, duplicados, inconsistencias.

Identificación y corrección de errores

En el proceso de limpieza y transformación de datos, la identificación y corrección de errores es crucial para asegurar la calidad y confiabilidad de los datos

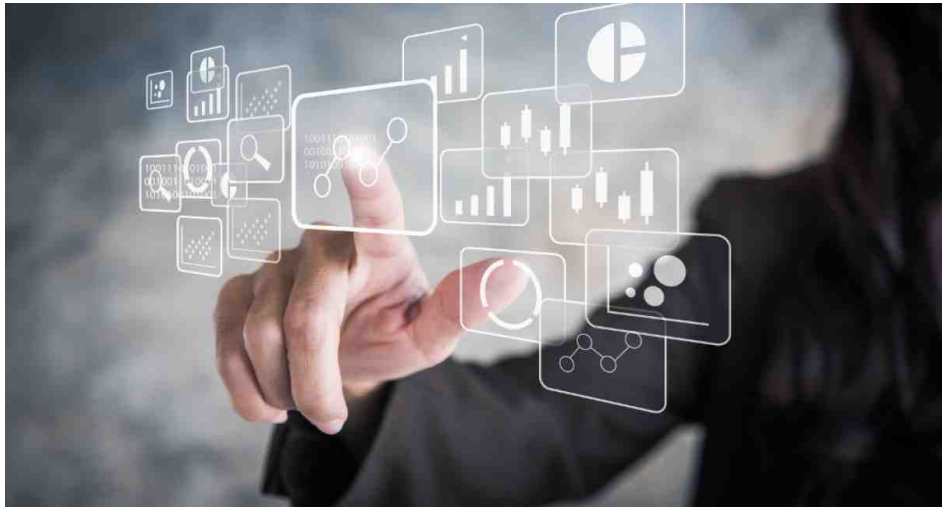

Identificación y corrección de errores

1 Valores Faltantes

- **Eliminación de filas o columnas**
- **Imputación de valores**: Sustituir valores faltantes con:
  - **Media o Mediana**
  - **Moda**
  - **Métodos avanzados**
- **Creación de una categoría especial**

2 Duplicados

Detección de duplicados

- **Eliminación de duplicados**
- **Consolidación de duplicados parciales**

3 Inconsistencias

- **Normalización de formatos**
- **Corrección de errores tipográficos**
- **Establecimiento de reglas de validación**

2.2.Transformación de datos: estandarización.

VALORES FALTANTES

Valores Faltantes: Eliminación de filas o columnas

Eliminación de filas o columnas: Si el porcentaje de valores faltantes en una fila o columna es alto, puede optarse por eliminarlos, siempre que esto no afecte significativamente el análisis.

Valores Faltantes: Imputación de valores

Imputación de valores: Es un proceso estadístico que consiste en sustituir los valores faltantes en un conjunto de datos por otros valores estimados. Se realiza para poder analizar los datos con técnicas estadísticas específicas.

La imputación preserva todos los casos reemplazando los datos faltantes con un valor estimado basado en otra información disponible.

ID	Nombre	Edad	Ciudad	Ingreso Mensual
1	Juan	30	Buenos Aires	45000
2	María		Córdoba	38000
3	Pedro	28		50000
4	Lucía	35	Mendoza	
5	Martín	40	Buenos Aires	60000

Valores Faltantes: Imputación de valores

Imputación de valores: Sustituir valores faltantes con:

- **Media o Mediana:** Para datos numéricos, dependiendo de si la distribución es normal o sesgada.
- **Moda**: Útil para datos categóricos.
- **Métodos avanzados:** Imputación usando modelos como KNN o regresión.

Valores Faltantes: Imputación de valores: Media o Mediana

Media o Mediana: Para datos numéricos, dependiendo de si la distribución es normal o sesgada (valor de un dato extremo).

Ejemplo práctico para entender cuándo usar la **media** o la **mediana** en datos numéricos faltantes, dependiendo de si la distribución es normal o sesgada:

Ejemplo: Ingresos Mensuales de Empleados

Tenemos un dataset de los ingresos mensuales de empleados en una empresa, y faltan algunos valores. Aquí están los ingresos conocidos (en dólares) de 10 empleados:

Empleado	Ingreso Mensual
1	2000
2	2200
3	2500
4	2600
5	2700
6	2800
7	3000
8	50000
9	2800
10	

Valores Faltantes: Imputación de valores: Media o Mediana

¿Media o Mediana?

Observa que tenemos un ingreso muy alto ($50,000) en comparación con el resto, lo cual podría ser un error o un valor extremo real.

También hay un valor faltante para el Empleado 10 que queremos imputar.

Empleado	Ingreso Mensual
1	2000
2	2200
3	2500
4	2600
5	2700
6	2800
7	3000
8	50000
9	2800
10	

Valores Faltantes: Imputación de valores: Media o Mediana

<u>Si usas la media:</u>

Calculamos la media (promedio) de todos los ingresos.

Media = (2000 + 2200 + 2500 + 2600 + 2700 + 2800 + 3000 + 50000 + 2800) / 9 ≈ **7433.33**

Este valor promedio ***es muy alto y no representa bien los ingresos típicos de los empleados*** debido al ingreso extremo de $50,000. Si usáramos la media para imputar el valor faltante, el ingreso mensual del Empleado 10 sería $7433.33, lo cual no es adecuado para reflejar los ingresos típicos.

Empleado	Ingreso Mensual
1	2000
2	2200
3	2500
4	2600
5	2700
6	2800
7	3000
8	50000
9	2800
10	

Valores Faltantes: Imputación de valores: Media o Mediana

Si usas la mediana:

Ordenamos los ingresos: 2000, 2200, 2500, 2600, 2700, 2800, 2800, 3000, 50000

La mediana es el valor en el centro de la lista ordenada, que es 2700.

Al imputar el valor faltante con la mediana, el ingreso del Empleado 10 sería $2700, que r***epresenta mejor los ingresos de la mayoría de los empleados***, ya que no se ve afectado por el valor extremo.

Empleado	Ingreso Mensual
1	2000
2	2200
3	2500
4	2600
5	2700
6	2800
7	3000
8	50000
9	2800
10	

Valores Faltantes: Imputación de valores: Moda

Moda: es el valor que aparece con mayor frecuencia en un conjunto de datos y es especialmente útil para variables categóricas.

Ejemplo práctico en el contexto de un restaurante que registra el tipo de comida preferida por sus clientes en una encuesta.

Ejemplo de Datos Categóricos:

Supongamos que los datos de preferencias de comida de un grupo de clientes son los siguientes:

Cliente	Preferencia de Comida
1	Italiana
2	Mexicana
3	Italiana
4	China
5	Italiana
6	Mexicana
7	Italiana
8	China
9	Mexicana

Valores Faltantes: Imputación de valores: Moda

Identificación de la Moda:

Para estos datos, observamos la frecuencia de cada preferencia de comida:

- Italiana: 4 veces
- Mexicana: 3 veces
- China: 2 veces

En este caso, la moda es "**Italiana**", ya que es el tipo de comida que más frecuentemente prefieren los clientes.

Cliente	Preferencia de Comida
1	Italiana
2	Mexicana
3	Italiana
4	China
5	Italiana
6	Mexicana
7	Italiana
8	China
9	Mexicana

Valores Faltantes: Imputación de valores: Moda

Uso de la Moda para Imputar Valores Faltantes:

Si en la columna "*Preferencia de Comida*" faltara el valor para un cliente (por ejemplo, si existiera el cliente 10, y no indicó su preferencia), podríamos imputar el valor "Italiana" para este cliente, *asumiendo que la moda es representativa de las preferencias generales del grupo*.

Cliente	Preferencia de Comida
1	Italiana
2	Mexicana
3	Italiana
4	China
5	Italiana
6	Mexicana
7	Italiana
8	China
9	Mexicana

Valores Faltantes: Imputación de valores: Métodos avanzados

Métodos avanzados de imputación como:

- **K-Nearest Neighbors (KNN),** y
- **Regresión**

Se utilizan para imputar valores faltantes basándose en patrones complejos dentro de los datos.

Valores Faltantes: Imputación de valores: Métodos avanzados

Imputación usando K-Nearest Neighbors (KNN)

Contexto: Tenemos un dataset de una tienda en línea que incluye información sobre clientes y sus hábitos de compra, pero algunos valores están faltantes en la columna de "*Ingresos Mensuales*".

Cliente	Edad	Ingreso Mensual	Género	Ciudad
1	25	45,000	M	Buenos Aires
2	30		F	Córdoba
3	35	60,000	F	Buenos Aires
4	29	50,000	M	Mendoza
5	40		F	Córdoba

Valores Faltantes: Imputación de valores: Métodos avanzados

Imputación usando K-Nearest Neighbors (KNN)

Aplicación del KNN:

- Con el algoritmo KNN, calculamos la similitud entre el cliente 2 (con datos faltantes) y otros clientes, en función de variables como la edad, el género y la ciudad.
- **El algoritmo selecciona los "K" clientes más cercanos** (por ejemplo, los 3 más similares) y utiliza sus valores de "Ingreso Mensual" para estimar el valor faltante para el cliente 2.
- Si los ingresos de los vecinos más cercanos (Clientes 1, 3, y 4) son $45,000, $60,000 y $50,000, el algoritmo podría imputar un valor promedio de $51,666 para el cliente 2.

Cliente	Edad	Ingreso Mensual	Género	Ciudad
1	25	45,000	M	Buenos Aires
2	30		F	Córdoba
3	35	60,000	F	Buenos Aires
4	29	50,000	M	Mendoza
5	40		F	Córdoba

Valores Faltantes: Imputación de valores: Métodos avanzados

Imputación usando Regresión

Contexto: Tenemos un dataset de estudiantes, algunos datos sobre la cantidad de horas de estudio están faltantes. Sin embargo, dispones de otras variables como calificaciones y asistencia, que pueden estar relacionadas con las horas de estudio.

Estudiante	Calificación	Asistencia (%)	Horas de Estudio
1	85	90	10
2	78	80	
3	92	95	15
4	88	88	12
5	75	70	

Valores Faltantes: Imputación de valores: Métodos avanzados

Imputación usando Regresión

Aplicación de Regresión:

- Utilizamos **regresión lineal** para modelar la relación entre las variables "*Calificación*" y "*Asistencia*" (predictoras) y "*Horas de Estudio*" (objetivo).
- Se entrena un modelo de regresión lineal con los estudiantes que tienen el dato de "*Horas de Estudio*" completo.
- *Luego, usamos el modelo entrenado para predecir las horas de estudio para estudiantes con datos faltantes en esta columna (por ejemplo, estudiante 2).*
- Si el modelo predice que el estudiante 2 debería estudiar alrededor de 8 horas en función de su calificación y asistencia, podemos imputar este valor.

Estudiante	Calificación	Asistencia (%)	Horas de Estudio
1	85	90	10
2	78	80	
3	92	95	15
4	88	88	12
5	75	70	

Ambos métodos aprovechan patrones en los datos existentes para generar imputaciones más precisas y realistas que otras técnicas básicas.

Valores Faltantes: Imputación de valores

Creación de una categoría especial:

Para variables categóricas, puede ser útil crear una categoría como "Desconocido" o "Sin información".

DUPLICADOS

Duplicados

- **Detección de duplicados**: Identificar filas repetidas mediante herramientas o scripts que comparan registros completos o campos específicos.

- **Eliminación de duplicados**: Tras identificar duplicados, eliminar las filas redundantes manteniendo una sola instancia del registro.

- **Consolidación de duplicados parciales**: En algunos casos, los duplicados pueden tener ligeras variaciones en ciertos campos. Aquí, la fusión o consolidación de los datos puede ser útil.

INCONSISTENCIAS

Inconsistencias

- **Normalización de formatos:** Asegurar que los datos tengan un formato homogéneo, por ejemplo, en fechas, capitalización de textos o unidades de medida.

- **Corrección de errores tipográficos:** Usar algoritmos de detección de similitudes o listas de valores válidos para corregir errores tipográficos o discrepancias en variables categóricas.

- **Establecimiento de reglas de validación:** Crear reglas y filtros para asegurar que los datos cumplen con ciertos criterios, como rangos de valores permitidos o relaciones entre variables.

¿Qué tan buena debe ser la calidad de los datos?

Valores Faltantes: Imputación de valores

Cómo Mejorar la Calidad de los Datos

Estandarización

Crear reglas claras para el formato y contenido de los datos

Limpieza Regular

Detectar y corregir errores de forma continua.

Validaciones Automáticas

Implementar controles que aseguren consistencia y completitud

Entrenamiento

Capacitar a quienes manipulan los datos para evitar errores

2.3 Profilado de datos y análisis exploratorio

¿Qué es el Profilado de Datos?

El profilado de datos ***es el proceso de examinar, analizar y resumir conjuntos de datos para conocer su estructura, contenido y calidad***.

Su objetivo principal es detectar problemas antes de usar los datos.

Permite identificar:

- Valores nulos o faltantes
- Valores duplicados
- Inconsistencias
- Valores fuera de rango
- Tipos de datos incorrectos
- Relaciones entre atributos

¿Qué es el Profilado de Datos?

Tipos de Profilado

a) Profilado de columna:
Analiza cada atributo individualmente.
Ejemplos:

- % de valores nulos
- Mínimo, máximo
- Media, mediana
- Distribución de valores

b) Profilado de estructura

Evalúa cómo están organizados los datos.
Ejemplos:

- Tipos de datos (numérico, texto, fecha)
- Longitud de campos
- Formatos (ej: fechas mal formateadas)

¿Qué es el Profilado de Datos?

Tipos de Profilado

c) Profilado de relaciones

Analiza dependencias entre columnas.

Ejemplos:

- Claves primarias duplicadas
- Integridad referencial
- Dependencias funcionales

d) Profilado de contenido

Busca patrones y anomalías.

Ejemplos:

- Valores inválidos ("N/A", "??")
- Inconsistencias semánticas
- Valores atípicos (outliers)

¿Qué es el Análisis Exploratorio de Datos (EDA)?

El **Análisis Exploratorio de Datos (EDA)** es un enfoque para comprender los datos mediante estadísticas y visualizaciones.

Va más allá del perfilado: busca entender comportamientos y patrones.

Objetivos del EDA:

- Comprender la distribución de los datos
- Detectar patrones ocultos
- Identificar outliers
- Evaluar relaciones entre variables
- Formular hipótesis

Técnicas comunes de EDA

Estadística descriptiva

- Media, mediana, moda
- Desviación estándar
- Percentiles

Visualizaciones

- Histogramas
- Boxplots
- Gráficos de dispersión

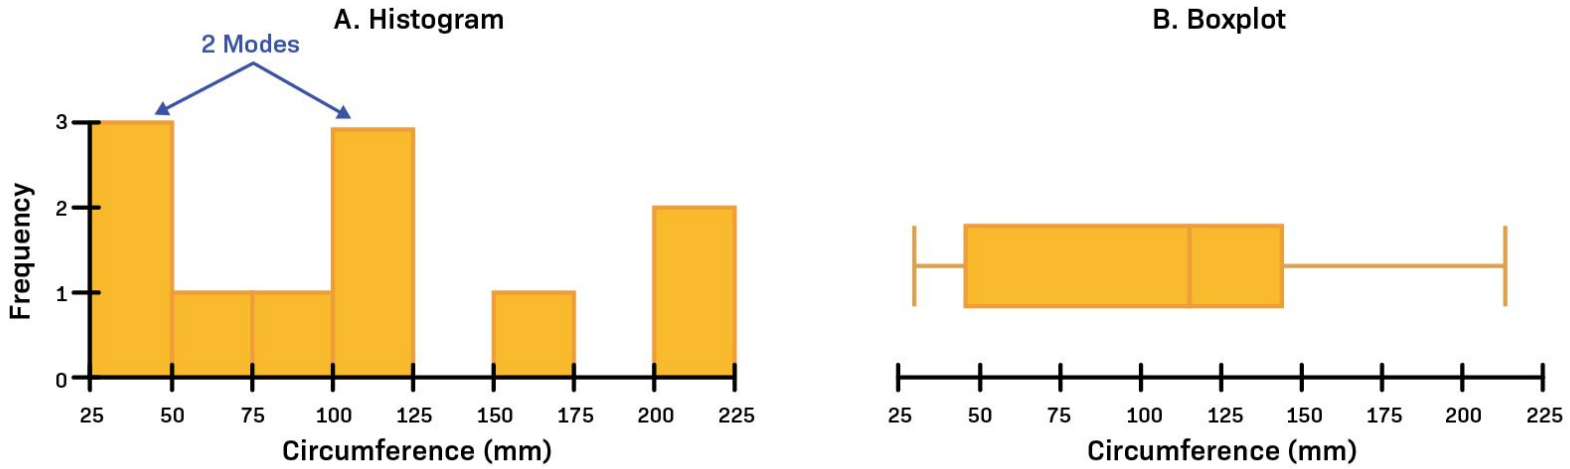

Análisis de correlación

Permite detectar relaciones entre variables.

Ejemplo: *Precio vs cantidad vendida*

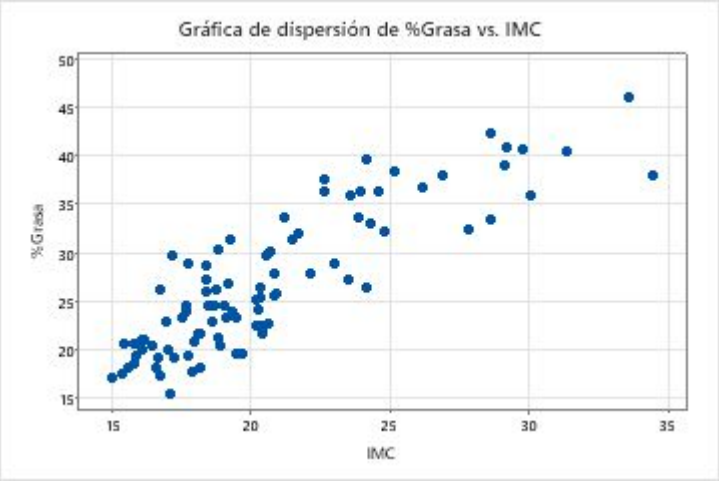

[PRÁCTICA ACTIVIDAD ASINCRÓNICA]

REGRESIÓN SIMPLE

Valores Faltantes: Imputación de valores: Métodos avanzados

Dra. Ing. Roxana Martínez