MÓDULO 2

Profilado, limpieza y transformación

PARTE II

Dra. Ing. Roxana Martínez

Temario

MÓDULO 2: PROFILADO, LIMPIEZA Y TRANSFORMACIÓN

2.3 Profilado de datos y análisis exploratorio
2.4 Validación e integridad
2.5 Herramientas prácticas: Python, SQL, Excel, Talend
2.6 Métricas iniciales de calidad

Ejercicio Actividad Asincrónica

2.3 Profilado de datos y análisis exploratorio

¿Qué es el perfilado de datos?

- Proceso de examinar y resumir datos
- Permite conocer estructura, contenido y calidad
- Detecta problemas antes del análisis
- Base para limpieza y transformación

Tipos de perfilado

- Perfilado de columna
  - % nulos, media, min/max
- Perfilado de estructura
  - Tipos de datos, formatos
- Perfilado de relaciones
  - claves, dependencias
- Perfilado de contenido
  - valores inválidos, outliers

Transformación y estandarización (continuación)

¿Por qué transformar los datos?

La transformación de datos permite:

- Asegurar consistencia
- Facilitar el análisis
- Preparar los datos para modelos analíticos o ML

Datos sin estandarizar → resultados incorrectos

Normalización de formatos

Consiste en unificar la forma en que se representan los datos.

Ejemplos comunes:

Fechas

01/02/2024 vs 2024-02-01

Texto

"Buenos Aires" vs "buenos aires" vs "Bs As"

Unidades

kg vs gramos

USD vs ARS

Normalización de formatos

Buenas prácticas:

- Definir formatos estándar
- Aplicar reglas automáticas
- Documentar cambios

Codificación de variables

Transformar variables categóricas en valores numéricos.

Los modelos analíticos requieren datos numéricos.

Tipos de codificación:

1. Label Encoding

- "Bajo" → 1
- "Medio" → 2
- "Alto" → 3

2. One-Hot Encoding

- "Rojo" → [1,0,0]
- "Azul" → [0,1,0]
- "Verde" → [0,0,1]

Útil cuando **no hay orden**

La codificación One-Hot (o One-Hot Encoding) es una técnica esencial en machine learning para convertir variables categóricas nominales en un formato numérico binario.

Problemas comunes en la integración

- Claves inconsistentes
- Datos duplicados
- Diferentes formatos
- Datos faltantes

Buenas prácticas

- Definir reglas de transformación
- Automatizar procesos
- Validar resultados
- Documentar cambios

¿Qué es el EDA?

- Análisis Exploratorio de Datos
- Uso de estadísticas y visualizaciones

Permite:

- detectar patrones
- identificar outliers
- entender distribuciones

Técnicas de EDA

- Estadística descriptiva
- media, mediana, desvío
- Visualizaciones
- Histogramas
- Boxplots
- Scatter plots
- Correlación entre variables

Actividad

Se proporciona un conjunto de datos que presenta problemas de calidad, incluyendo formatos inconsistentes (fechas y textos), variables categóricas sin codificar y atributos numéricos en distintas escalas.
El objetivo de la actividad es aplicar técnicas de transformación y estandarización para preparar el dataset para su análisis. En particular, se solicita normalizar los formatos, codificar las variables categóricas y escalar las variables numéricas.

Finalmente, reflexionar sobre cómo estas transformaciones impactan en la calidad y usabilidad de los datos.

https://datos.gob.ar/

Dataset con:

- Fechas en distintos formatos
- Categorías sin codificar
- Variables en distintas escalas

Consigna:

- Normalizar formatos
- Codificar variables

2.4 Validación e integridad

Validación e integridad

¿Qué es la validación de datos?

- Proceso de verificar que los datos sean correctos
- Asegura calidad y confiabilidad
- Se basa en reglas definidas

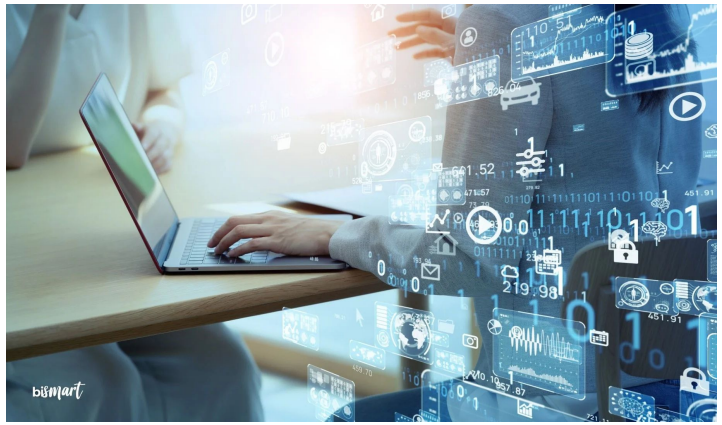

Tipos de validación

- Validación de formato (fechas, emails)
- Validación de rango (edad > 0)
- Valores obligatorios
- Validación cruzada entre campos

Validación e integridad

Integridad de datos

Integridad de dominio
Integridad de entidad (clave primaria)
Integridad referencial (claves foráneas)

Validaciones automáticas

- Reglas en sistemas
- Constraints en bases de datos
- Validaciones en ETL
- Beneficios:
  - reduce errores
  - mejora consistencia

La integridad de datos en SQL se basa en un esquema rígido y propiedades ACID (atomicidad, consistencia, aislamiento, durabilidad), garantizando alta fiabilidad para transacciones financieras. En contraste, NoSQL prioriza la flexibilidad y escalabilidad horizontal, sacrificando a menudo la consistencia inmediata (teorema CAP) por un rendimiento rápido en grandes volúmenes de datos

Elementos clave de la limpieza de datos

Elementos clave de la limpieza de datos

Identificar problemas:

- Errores tipográficos: Valores mal ingresados (por ejemplo, "Argentia" en lugar de "Argentina").
- Valores faltantes: Campos vacíos o nulos.
- Valores atípicos (outliers): Datos que están fuera de los rangos esperados.
- Inconsistencias: Formatos no estandarizados (fechas en formatos mixtos como "DD/MM/YYYY" y "MM-DD-YYYY").

Elementos clave de la limpieza de datos

Acciones comunes:

- Eliminar duplicados: Para evitar redundancias en el análisis.
- Corregir errores: Actualizar datos basados en reglas o fuentes confiables.
- Imputar datos faltantes: Completar valores vacíos con estrategias como la media, mediana o modelado.
- Normalizar o estandarizar: Asegurar que todos los datos sigan un formato uniforme.
- Filtrar datos irrelevantes: Eliminar datos que no son necesarios para el objetivo del análisis.

Elementos clave de la limpieza de datos

Validar los resultados:

- Asegurarse de que el conjunto de datos limpio cumpla con las especificaciones del análisis y no se haya perdido información importante por error.

Importancia de la limpieza de datos

Aumenta la precisión: Minimiza errores que pueden distorsionar resultados.

Mejora la eficiencia: Datos limpios permiten análisis más rápidos y efectivos.

Evita sesgos: Los errores en los datos pueden conducir a conclusiones incorrectas.

Validación de Datos: Verificación de la Integridad y Consistencia

Integridad:

- Garantizar que los datos no estén dañados ni incompletos.
- Cumplir con restricciones de integridad como claves primarias, relaciones entre tablas o reglas de negocio.

Consistencia:

- Asegurar que los datos tienen un formato uniforme en todo el conjunto.
- Detectar discrepancias como duplicados, formatos diferentes para el mismo tipo de dato o valores contradictorios.

Calidad:

- Detectar y corregir errores humanos, técnicos o de integración.
- Verificar que los datos cumplen con los requisitos del análisis o sistema.

Profilado de datos: Análisis exploratorio de datos. Herramienta Talend.

Profilado de datos: Análisis exploratorio de datos.

El **profilado de datos** es el proceso de analizar y resumir las características de un conjunto de datos para comprender su calidad, estructura y contenido antes de realizar un análisis profundo o un procesamiento.

Es una etapa crítica del **análisis exploratorio de datos (EDA, por sus siglas en inglés)**, que se utiliza para descubrir patrones, identificar inconsistencias y evaluar la limpieza y preparación necesaria.

Profilado de datos: Análisis exploratorio de datos.

Objetivos del Profilado de Datos

- ➔ *Comprender la estructura de los datos:* Analizar tipos de datos, formatos, longitudes y relaciones entre columnas.
- ➔ *Evaluar la calidad de los datos:* Detectar valores faltantes, duplicados o atípicos.
- ➔ *Descubrir patrones:* Identificar distribuciones, correlaciones y tendencias en los datos.
- ➔ *Facilitar la toma de decisiones:* Preparar estrategias para limpiar, transformar o integrar los datos.

Elementos del Profilado de datos

- **Resumen estadístico:**
  - **Valores mínimos, máximos, promedio, mediana.**
  - **Distribución de frecuencias.**
  - **Desviación estándar.**

- **Análisis de calidad de datos:**
  - **Porcentaje de valores faltantes o vacíos.**
  - **Duplicados y errores.**

Elementos del Profilado de datos

- **Análisis de relaciones:**
  - **Correlaciones entre variables.**
  - **Dependencias y cardinalidades.**

- **Identificación de inconsistencias:**
  - **Formatos mixtos (fechas, textos).**
  - **Valores fuera de rango.**

2.5 Herramientas prácticas: Python, SQL, Excel, Talend

Importancia de las herramientas

Permiten automatizar procesos

Escalar análisis de datos

Reducir errores manuales

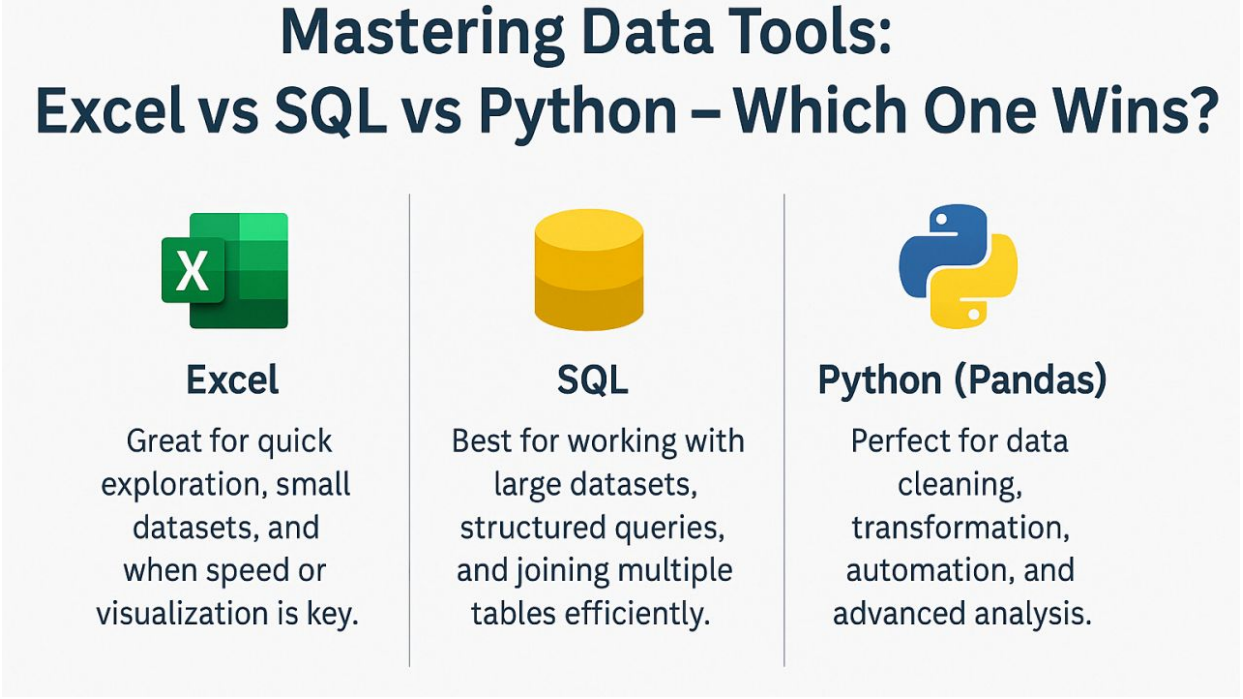

Python

Python (pandas)

isnull(), dropna()

duplicated()

fillna()

Ventaja: flexibilidad y automatización

https://pandas.pydata.org/

SQL

COUNT(), DISTINCT

GROUP BY

Detección de duplicados

Validaciones con WHERE

Excel / Talend

Excel:

- Filtros
- Formato condicional
- Tablas dinámicas

Talend (ETL):

- Integración de datos
- Limpieza automatizada
- Flujos de transformación

Herramienta Talend.

Talend para el Profilado de Datos

Talend es una plataforma que proporciona herramientas integrales para la integración y gestión de datos, incluida la funcionalidad de **Data Profiling**. Su módulo **Talend Data Preparation** permite realizar análisis exploratorios eficientemente, facilitando tareas de limpieza y transformación.

talend*
*open data solutions

Talend para el Profilado de Datos

Funcionalidades clave de Talend para Profilado:

1. **Interfaz gráfica**: Talend ofrece una interfaz intuitiva para explorar y analizar datos sin necesidad de programar.
2. **Estadísticas automáticas**: Genera automáticamente métricas como distribuciones, valores faltantes y duplicados.
3. **Visualización**: Permite visualizar los datos y sus características mediante gráficos y tablas interactivas.
4. **Reglas de calidad personalizables**: Identifica problemas de calidad y permite definir reglas específicas para los datos.
5. **Integración con ETL**: Talend facilita la integración directa del profilado en flujos de trabajo de transformación y carga de datos.

Talend para el Profilado de Datos

1.¿Que es Talend? | Talend en español | Talend Data Integration

https://youtu.be/3e7MycjUPWY?si=-7NykzBzN8CktPZ5

2.¿Qué es la Integración de Datos? | Talend en español | Talend Data Integration

https://youtu.be/kDMy2prnfEE?si=f6iMF6JgOf0hJyx9

Talend Open Studio (Gratuita)

Herramienta de integración de datos gratuita y de código abierto. Está diseñada para tareas como ETL (Extract, Transform, Load) y data profiling básico.

Talend Data Fabric y Talend Cloud (De pago)

Son las versiones comerciales que integran una suite completa de herramientas para gestión avanzada de datos, incluyendo data profiling, data cleansing, integración en tiempo real, y gobernanza de datos.

Validación de datos: Verificación de la integridad y consistencia de los datos.

ANEXO: Talend: Integridad de Datos

¿Qué es la Integración de Datos? | Talend en español | Talend Data Integration

https://youtu.be/kDMy2prnfEE?si=f6iMF6JgOf0hJyx9

¿Qué es el proceso ETL?

https://youtu.be/FO7nScExZjA?si=mSfWE-FtURv7KA4U

Instalación de Talend Open Studio | Talend en español | Talend Data Integration

https://youtu.be/KdTZAGmNeKg?si=XPmo28Cajwxah8Gg

ANEXO: Talend: Integridad de Datos

Caracteristicas de las ventanas en Talend Open Studio | Talend en español -Talend Data Integration

https://youtu.be/WxiejFj8nQ4?si=3e62Xw6LBlZyQHzN

2.6 Métricas iniciales de calidad

Métricas de Calidad de Datos

Las métricas de calidad de datos pueden variar según los autores, los enfoques y los contextos en los que se apliquen. Aquí hay algunas métricas comunes utilizadas para evaluar la calidad de datos:

1. **Exactitud (Accuracy)**: Definición: "La exactitud de los datos se refiere al grado en que los valores registrados representan fielmente la realidad o la verdad en un conjunto de datos." (Smith, J., 2018).

2. **Integridad (Completeness)**: Definición: "La integridad de los datos se refiere al nivel de completitud en un conjunto de datos, es decir, la proporción de valores presentes en relación con los valores esperados o requeridos." (Johnson, R., 2020).

Métricas de Calidad de Datos

3. Consistencia (Consistency): Definición: "La consistencia de los datos implica la uniformidad y coherencia en términos de formatos, unidades y codificaciones dentro de un conjunto de datos o entre diferentes bases de datos." (Brown, A., 2019).

4. Actualidad (Currency): Definición: "La actualidad de los datos se refiere a qué tan recientes son los valores registrados en comparación con el tiempo real en un conjunto de datos." (García, M., 2021).

Métricas de Calidad de Datos

5. Validez (Validity): Definición: "La validez de los datos evalúa si los valores registrados cumplen con las reglas y restricciones establecidas para el tipo de datos que representan." (Lee, S., 2017).

6. Unicidad (Uniqueness): Definición: "La unicidad de los datos mide la presencia de registros duplicados o redundantes en un conjunto de datos, buscando asegurar que cada entidad esté representada por un solo registro." (Wang, Q., 2022).

7. Trazabilidad (Traceability): Definición: "La trazabilidad de los datos se refiere a la capacidad de rastrear y documentar el origen y el flujo de datos desde su fuente original hasta su destino final." (Chen, L., 2019).

Métricas de Calidad de Datos

Aspectos de Calidad: Norma y Estándares

Algunas de las normas que se enfocan en este tipo de aspectos de calidad son:

- ISO/IEC 25012 [ISO08], que define el estudio de las características de la calidad de datos entorno a la evaluación basada en los estándares internacionales.
- ISO/IEC 25024 [ISO24], que define medidas de calidad de datos para medir cuantitativamente la calidad de los datos en términos de características definidas en ISO/IEC 25012.
- ISO/IEC 25040 [ISO40], que define los requisitos y recomendaciones para la evaluación de la calidad del producto de software y aclara los conceptos generales. Además, ofrece una descripción del proceso para evaluar la calidad como así también, presenta el detalle de los requisitos para la aplicación de este.

Aspectos a tener en cuenta…

DAMA-DMBOK (Data Management Body of Knowledge):
Es un marco de referencia elaborado por la asociación DAMA International que reúne las mejores prácticas, guías y estándares para la gestión de datos en las organizaciones. Cubre áreas como gobierno de datos, calidad, arquitectura, seguridad y almacenamiento.
Es una guía o manual de buenas prácticas para la gestión de datos en organizaciones. Explica cómo manejar datos de forma ordenada, segura y útil (como una especie de "enciclopedia" de la gestión de datos).

ISO 8000 (Calidad de Datos):
Es un estándar internacional de la ISO que establece requisitos para asegurar la **calidad e intercambio de datos** entre sistemas. Se centra en aspectos como precisión, consistencia, completitud y portabilidad de los datos para garantizar su confiabilidad.
Es una **norma internacional** que define criterios para asegurar la **calidad de los datos**, especialmente cuando se comparten o intercambian entre sistemas y organizaciones.

[PRÁCTICA ACTIVIDAD ASINCRÓNICA]

python + colab

Profilado y EDA con Python

Dra. Ing. Roxana Martínez