MÓDULO 3

MÉTRICAS E INDICADORES DE CALIDAD

PARTE I

Dra. Ing. Roxana Martínez

Temario

MÓDULO 3: MÉTRICAS E INDICADORES DE CALIDAD

3.1 Medición de la calidad de los datos
3.2 Indicadores de calidad (DQI)
3.3 Diseño de métricas alineadas al negocio
3.4 Visualización de resultados con dashboards

Ejercicio Actividad Asincrónica

3.1 Medición de la calidad de los datos

Medición de la calidad de los datos

¿Qué significa "medir" calidad?

Dimensiones típicas:

- Completitud
- Exactitud
- Consistencia
- Validez
- Unicidad
- Actualización (timeliness)

Medición de la calidad de los datos

"No se puede mejorar lo que no se mide"

Ejemplo simple

Dataset de pacientes:

- % de registros sin DNI → completitud
- Edad negativa → validez
- Mismo paciente duplicado → unicidad

Mini actividad

¿Qué problemas de calidad ven?

	A	B	C	D	E
1	**id_paciente**	**nombre**	**edad**	**dni**	**fecha_registro**
2	1	Ana	25	12345678	2024-01-10
3	2	Juan	-5	87654321	2024-02-15
4	3		40		2024-13-01
5	3	Carlos	40	87654321	2024-02-15
6	5	María		11223344	
7	6	Luis	30	55667788	2024-03-20
8	7	Ana	25	12345678	2024-01-10

Mini actividad

Mini actividad: Calidad de Datos

Observá el dataset y detectá problemas de calidad.

[1]
0 s

```python
import pandas as pd

data = {
    "id_paciente": [1, 2, 3, 3, 5, 6, 7],
    "nombre": ["Ana", "Juan", None, "Carlos", "María", "Luis", "Ana"],
    "edad": [25, -5, 40, 40, None, 30, 25],
    "dni": ["12345678", "87654321", None, "87654321", "11223344", "55667788", "12345678"],
    "fecha_registro": ["2024-01-10", "2024-02-15", "2024-13-01", "2024-02-15", None, "2024-03-20", "2024-01-10"]
}

df = pd.DataFrame(data)
df
```

Mini actividad

1 to 7 of 7 entries Filter

index	id_paciente	nombre	edad	dni	fecha_registro
0	1	Ana	25.0	12345678	2024-01-10
1	2	Juan	-5.0	87654321	2024-02-15
2	3		40.0		2024-13-01
3	3	Carlos	40.0	87654321	2024-02-15
4	5	María	NaN	11223344	
5	6	Luis	30.0	55667788	2024-03-20
6	7	Ana	25.0	12345678	2024-01-10

Show 25 per page

Like what you see? Visit the data table notebook to learn more about interactive tables.

Pasos siguientes: Generar código con df New interactive sheet

Mini actividad

Análisis automático (docente)

[ ]

```python
print("Valores nulos:")
print(df.isnull().sum())

print("\nDuplicados:")
print(df[df.duplicated()])

print("\nEdades inválidas:")
print(df[df["edad"] < 0])

df["fecha_registro"] = pd.to_datetime(df["fecha_registro"], errors='coerce')
print("\nFechas inválidas:")
print(df[df["fecha_registro"].isnull()])
```

```
Valores nulos:
id_paciente       0
nombre            1
edad              1
dni               1
fecha_registro    1
dtype: int64

Duplicados:
Empty DataFrame
Columns: [id_paciente, nombre, edad, dni, fecha_registro]
Index: []

Edades inválidas:
   id_paciente nombre  edad       dni fecha_registro
1            2   Juan  -5.0  87654321     2024-02-15

Fechas inválidas:
   id_paciente nombre  edad       dni fecha_registro
2            3   None  40.0      None            NaT
4            5  María   NaN  11223344            NaT
```

3.2 Indicadores de Calidad (DQI)

Data Quality

Un DQI (Data Quality Indicator) es una métrica cuantificable que refleja el estado de una dimensión de calidad.

Ejemplos concretos

- % de valores nulos
- % de duplicados
- % de registros válidos
- % de consistencia entre sistemas

Data Quality

Fórmulas simples

Completitud:

$$\frac{\text{valores no nulos}}{\text{total de valores}}$$

Data Quality

Fórmulas simples

Duplicados:

$$\frac{\text{registros duplicados}}{\text{total de registros}}$$

Componentes de un DQI

Un DQI bien definido tiene al menos 5 elementos:

- Dimensión de calidad: Ej: completitud, exactitud, consistencia
- Definición formal: Qué mide exactamente
- Fórmula de cálculo: Cómo se cuantifica
- Umbral (threshold): Qué valor es aceptable
- Contexto de uso: Para qué proceso/decisión sirve

DQI: Ejemplo completo

DQI: Completitud de DNI en pacientes

Dimensión: Completitud

Definición: Proporción de registros con DNI informado

Fórmula:

$$\frac{\text{registros con DNI}}{\text{total de registros}}$$

Umbral: ≥ 98%

Contexto: Identificación única de pacientes

Dimensiones de calidad más utilizadas

Dimensión	Qué mide	Ejemplo de DQI
Completitud	Datos faltantes	% nulos
Exactitud	Corrección del dato	% valores correctos
Consistencia	Coherencia entre datos	% reglas cumplidas
Validez	Cumplimiento de formato/reglas	% valores válidos
Unicidad	No duplicación	% registros únicos
Actualidad	Vigencia temporal	% datos actualizados

Error común

Confundir:

- Dimensión ≠ DQI

Ej:

- “Completitud” → dimensión
- “% de valores no nulos” → DQI

Alineación con negocio

Un DQI sin contexto de negocio:
es solo un número

Un DQI bien diseñado:
impacta decisiones

Error común/Alineación con negocio

Confundir:

- Dimensión ≠ DQI

Ej:

- “Completitud” → dimensión
- “% de valores no nulos” → DQI

Alineación con negocio

Un DQI sin contexto de negocio:
es solo un número

Un DQI bien diseñado:
impacta decisiones

Alineación con negocio

Alineación con negocio

Un DQI sin contexto de negocio:
es solo un número

Un DQI bien diseñado:
impacta decisiones

Ejemplo comparativo

Técnico

- % nulos en email = 20%

Negocio

- 20% de clientes no pueden ser contactados → impacto en campañas

Ciclo de vida de un DQI

1. Definición
2. Implementación
3. Medición periódica
4. Monitoreo
5. Acción (corrección)

Sin acción → no hay gestión de calidad

3.3 Diseño de métricas alineadas al negocio

Métricas

No todas las métricas importan: importan las que impactan en decisiones

Ejemplos Prácticos

Ejemplo 1: Salud

Problema: errores en datos de donantes

Métrica relevante: % de datos completos en variables críticas (grupo sanguíneo, edad)

Ejemplos Prácticos

Ejemplo 2: RRHH

Problema: mala calidad en CVs

Métrica: % de perfiles con información completa para selección

Ejemplos Prácticos

Ejemplo 3 (Finanzas)

Problema: inconsistencias en reportes

Métrica: % de registros consistentes entre fuentes

3.4 Visualización con dashboards

Dashboard

Un dashboard NO es solo gráfico → es toma de decisión

<u>Buenas prácticas:</u>

- Simplicidad
- KPIs claros
- Uso de colores (alertas)
- Evolución temporal

Ejemplo de dashboard de calidad

- % completitud (gauge o barra)
- % duplicados
- tendencia de calidad en el tiempo
- alertas (rojo/verde)

“¿Qué debería tener un dashboard de calidad?”

- KPIs → completitud, duplicados
- Evolución → tendencias en el tiempo
- Alertas → soporte a decisión

KPI claros

Evolución temporal

Interpretación (no solo gráfico)

Umbrales → toma de decisión

“¿Qué debería tener un dashboard de calidad?”

python + colab

```python
import pandas as pd
import matplotlib.pyplot as plt

# --------------------------
# 1. Dataset simulado
# --------------------------
data = {
    "fecha": pd.date_range(start="2024-01-01", periods=10, freq='M'),
    "total_registros": [100, 120, 110, 130, 125, 140, 150, 160, 155, 170],
    "nulos": [10, 15, 8, 20, 18, 25, 30, 28, 26, 35],
    "duplicados": [5, 6, 4, 7, 6, 8, 10, 9, 8, 11]
}

df = pd.DataFrame(data)
```

“¿Qué debería tener un dashboard de calidad?”

python + colab

```python
# ---------------------------
# 2. KPIs de calidad
# ---------------------------
df["completitud"] = 1 - (df["nulos"] / df["total_registros"])
df["pct_duplicados"] = df["duplicados"] / df["total_registros"]

# Mostrar tabla
print("📋 Dataset con métricas de calidad:")
display(df)

# ---------------------------
# 3. KPI actuales (último período)
# ---------------------------
ultimo = df.iloc[-1]

print("\n📊 KPIs actuales:")
print(f"Completitud: {ultimo['completitud']:.2%}")
print(f"% Duplicados: {ultimo['pct_duplicados']:.2%}")
```

“¿Qué debería tener un dashboard de calidad?”

python + colab

```python
# ---------------------------
# 4. Dashboard (gráficos)
# ---------------------------

# 📈 Evolución de completitud
plt.figure()
plt.plot(df["fecha"], df["completitud"], marker='o')
plt.title("Evolución de Completitud")
plt.xlabel("Fecha")
plt.ylabel("Completitud")
plt.xticks(rotation=45)
plt.grid()
plt.show()

# 📉 Evolución de duplicados
plt.figure()
plt.plot(df["fecha"], df["pct_duplicados"], marker='o')
plt.title("Evolución de % Duplicados")
plt.xlabel("Fecha")
plt.ylabel("% Duplicados")
plt.xticks(rotation=45)
plt.grid()
plt.show()
```

“¿Qué debería tener un dashboard de calidad?”

python + colab

```python
# ---------------------------
# 5. Alertas simples
# ---------------------------
umbral_completitud = 0.9
umbral_duplicados = 0.1

print("\n🚨 Alertas:")

if ultimo["completitud"] < umbral_completitud:
    print("⚠️ Baja completitud detectada")
else:
    print("✅ Completitud OK")

if ultimo["pct_duplicados"] > umbral_duplicados:
    print("⚠️ Alto nivel de duplicados")
else:
    print("✅ Duplicados OK")
```

“¿Qué debería tener un dashboard de calidad?”

python + colab

¿Qué observas?

Cierre

Pregunta disparadora

"¿Qué pasa si una organización no mide la calidad de sus datos?"

<u>Conclusión:</u>

La calidad de datos impacta directamente en:

- decisiones
- modelos de IA
- políticas públicas

[PRÁCTICA ACTIVIDAD ASINCRÓNICA]

python + colab

Métricas con dashboard

Dra. Ing. Roxana Martínez